

# **Decision Tree**

Supervised Learning



## **Background**

- Decision trees have a long history in machine learning
- The first popular algorithm dates back to 1979
- Very popular in many real world problems
  - Intuitive to understand
  - Easy to build



#### **Motivation**

- How do people make decisions?
  - Consider a variety of factors
  - Follow a logical path of checks
- An Example
  - Should I eat at this restaurant?
    - If there is no wait
      - Yes
  - If there is short wait and I am hungry
    - Yes
  - Else
    - No



## **Advantages**

- Handling of categorical variables
- Handling of missing values and unknown labels
- Detection of nonlinear relationships
- Visualization and interpretation in decision trees



#### When to consider Decision Trees

- Instances describable by attribute-value pairs
- Target function is discrete valued
- Disjunctive hypothesis may be required
   会
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
   中
- Possibly noisy training data
- Missing attribute values

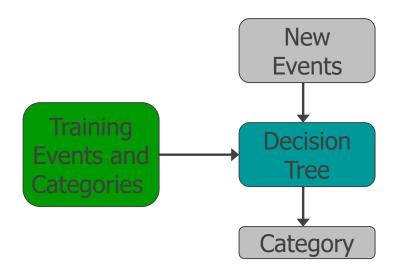
#### Examples:

- Medical diagnosis
- Credit risk analysis
- Object classification for robot manipulator (Tan 1993)



#### Introduction

Use a decision tree to predict categories for new events. Use training data to build the decision tree.





#### Introduction

A decision tree has 2 kinds of nodes

- 1. Each **leaf node** has a class label, determined by majority vote of training examples reaching that leaf.
- 2. Each **internal node** is a question on features. It branches out according to the answers.



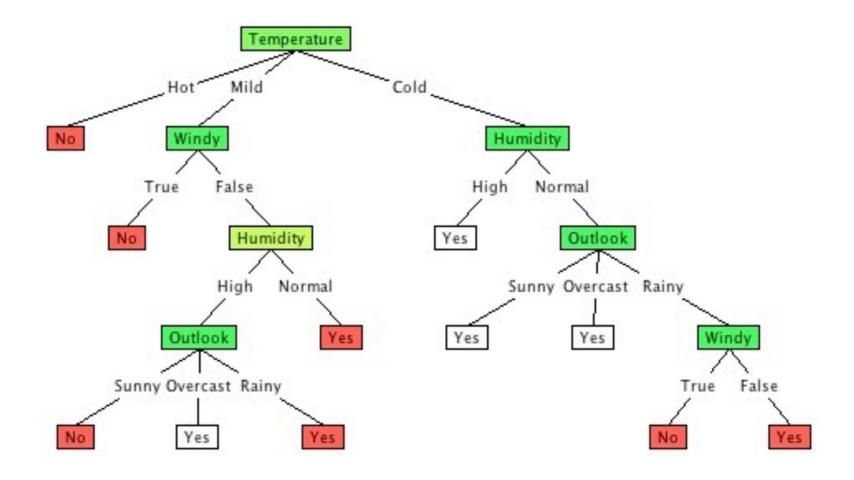
## **Decision Tree for Play Tennis**

| Play Tennis | Outlook  | Temperature | Humidity | Windy |  |
|-------------|----------|-------------|----------|-------|--|
| No          | Sunny    | Hot         | High     | No    |  |
| No          | Sunny    | Hot         | High     | Yes   |  |
| Yes         | Overcast | Hot         | High     | No    |  |
| Yes         | Rainy    | Mild        | High     | No    |  |
| Yes         | Rainy    | Cold        | Normal   | No    |  |

If temperature is not hot → Play
If outlook is overcast → Play
Otherwise → Don't play tennis

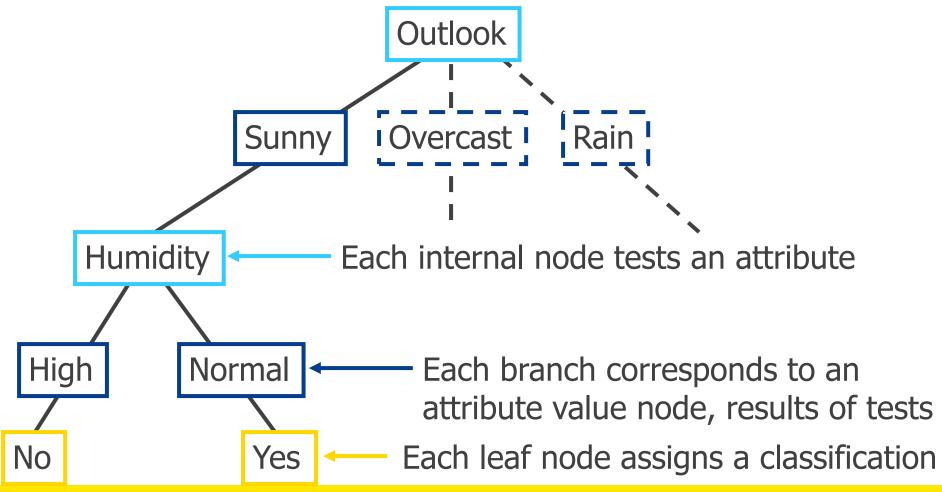


## **Decision Tree for Play Tennis**





## **Decision Tree for PlayTennis - Structure**



#### Small tree:

- Occam's razor: a guideline to help us choose. Simpler is better
- Avoids over-fitting





• Occam's razor: a guideline to help us choose. Simpler is better







• Occam's razor: a guideline to help us choose. Simpler is better

#### Prank explanation requires:

- 1. Human (not observed)
- 2. Ability to enter house (unknown)
- 3. Motive to play prank (unknown)
- 4. Leaving no other trace (observed)

#### Licking explanation requires:

- 1. Cat (observed)
- 2. Licking (observed)



- A decision tree may be human readable, but not use human logic!
- How do we build small trees that accurately capture data?
- Learning an optimal decision tree is computationally intractable



## **Greedy Algorithm**

- We can get good trees by simple greedy algorithms
- Adjustments are usually to fix greedy selection problems

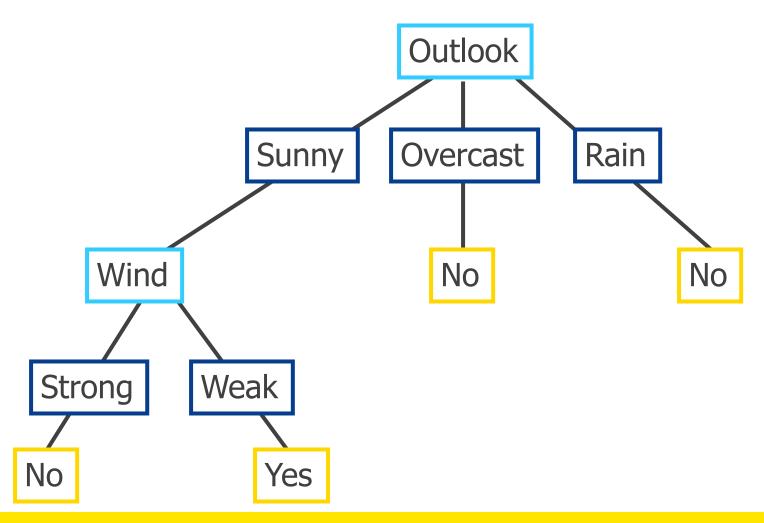
#### Recursive:

- 1. Select the "best" variable, and generate child nodes: One for each possible value;
- 2. Partition samples using the possible values, and assign these subsets of samples to the child nodes;
- 3. Repeat for each child node until all samples associated with a node that are either all positive or all negative.



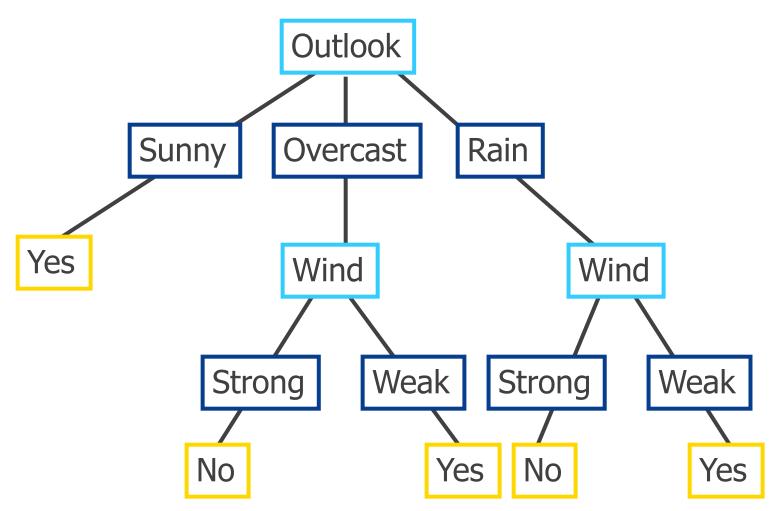
## **Decision Tree for Conjunction**

Outlook=Sunny \( \text{ Wind=Weak} \)



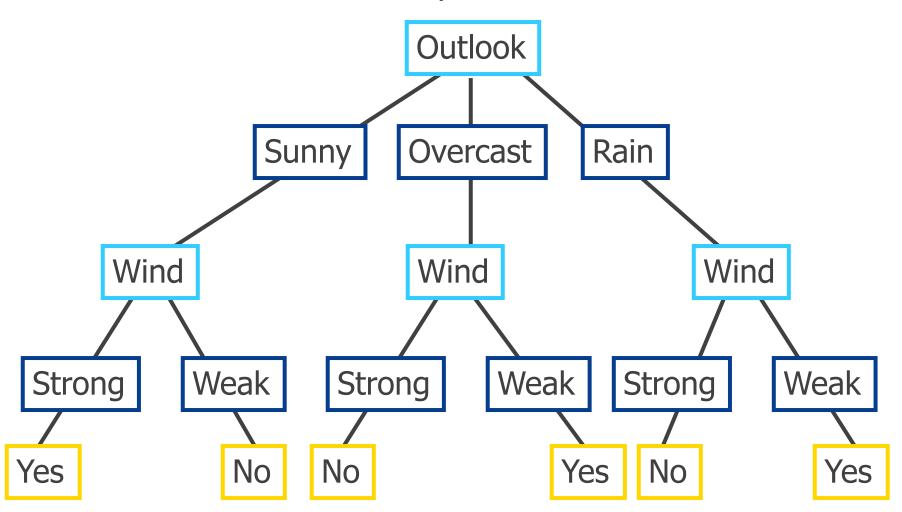
## **Decision Tree for Disjunction**

Outlook=Sunny ∨ Wind=Weak



#### **Decision Tree for XOR**

Outlook=Sunny XOR Wind=Weak





## **Top-Down Induction of Decision Trees ID3**

- 1. A  $\leftarrow$  the "best" decision attribute for next *node*
- 2. Assign A as decision attribute for *node*
- 3. For each value of A create new descendant
- 4. Sort training examples to leaf node according to the attribute value of the branch
- 5. If all training examples are perfectly classified (same value of target attribute) stop, else iterate over new leaf nodes.



#### Variable Selection

#### The best variable for partition

- The most informative variable
- Select the variable that is most informative about the labels

The quantification of information

Founded by Claude Shannon

#### Basic concepts

Entropy: 
$$H(X) = -\sum_{x} \mathbb{P}(X = x) \log \mathbb{P}(X = x)$$

Conditional Entropy: 
$$H(Y|X) = \sum_{x} \mathbb{P}(X=x)H(Y|X=x)$$

Information Gain: 
$$IG(Y|X) = H(Y) - H(Y|X)$$

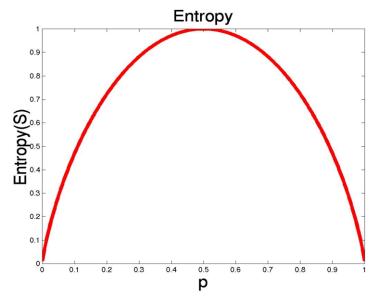
Select the variable with the highest information gain



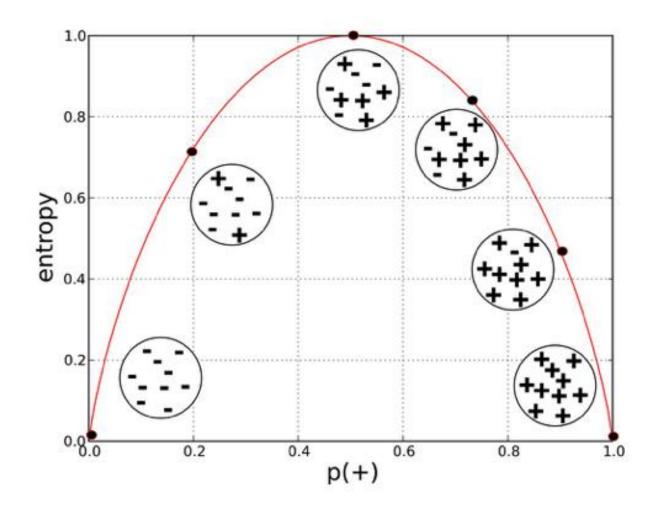
## **Entropy**

S is a sample of training examples p<sub>+</sub> is the proportion of positive examples p<sub>-</sub> is the proportion of negative examples Entropy measures the impurity of S

• Entropy(S) = -p+  $\log_2 p_+$  -  $p_- \log_2 p_-$ 



# **Entropy**



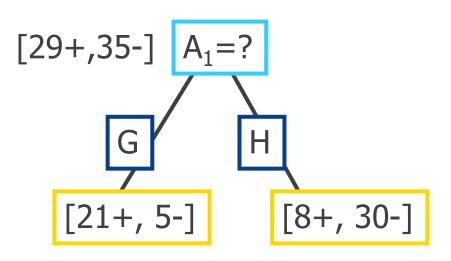


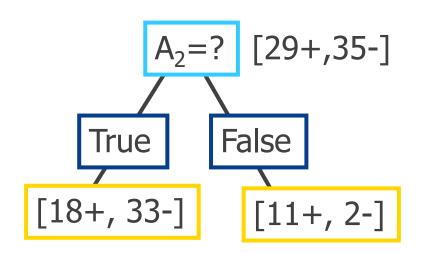
## Information Gain (S=E)

Gain(S,A): expected reduction in entropy due to sorting S on attribute A

Entropy(
$$[29+,35-]$$
) = -29/64 log2 29/64 - 35/64 log2 35/64  
= 0.99

$$Gain(S, A) \equiv Entropy(S) - \sum_{v \in D_A} \frac{|S_v|}{|S|} Entropy(S_v)$$







## **Training Examples**

| Day | Outlook  | Temp. | Humidity | Wind   | Play Tennis |  |
|-----|----------|-------|----------|--------|-------------|--|
| D1  | Sunny    | Hot   | High     | Weak   | No          |  |
| D2  | Sunny    | Hot   | High     | Strong | No          |  |
| D3  | Overcast | Hot   | High     | Weak   | Yes         |  |
| D4  | Rain     | Mild  | High     | Weak   | Yes         |  |
| D5  | Rain     | Cool  | Normal   | Weak   | Yes         |  |
| D6  | Rain     | Cool  | Normal   | Strong | No          |  |
| D7  | Overcast | Cool  | Normal   | Weak   | Yes         |  |
| D8  | Sunny    | Mild  | High     | Weak   | No          |  |
| D9  | Sunny    | Cold  | Normal   | Weak   | Yes         |  |
| D10 | Rain     | Mild  | Normal   | Strong | Yes         |  |
| D11 | Sunny    | Mild  | Normal   | Strong | Yes         |  |
| D12 | Overcast | Mild  | High     | Strong | Yes         |  |
| D13 | Overcast | Hot   | Normal   | Weak   | Yes         |  |
| D14 | Rain     | Mild  | High     | Strong | No          |  |



## **Selecting the Next Attribute**

The information gain values for the 4 attributes are:

- Gain(S,Outlook) = 0.247
- Gain(S, Humidity) = 0.151
- Gain(S,Wind) =0.048
- Gain(S,Temperature) = 0.029

where S denotes the collection of training examples



#### Occam's Razor

"If two theories explain the facts equally weel, then the simpler theory is to be preferred"

#### Arguments in favor:

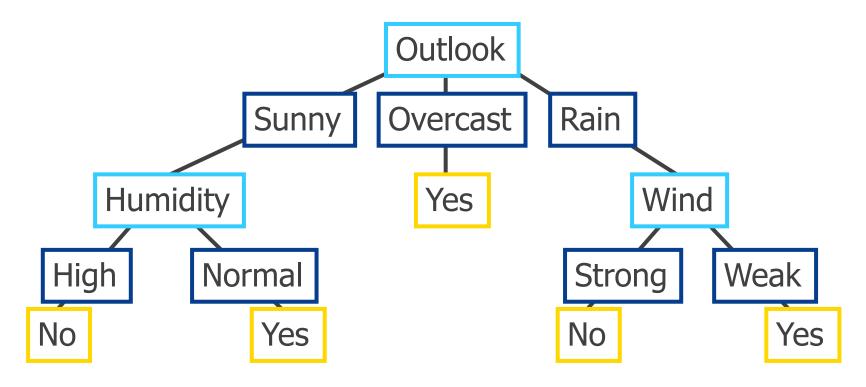
- Fewer short hypotheses than long hypotheses
- A short hypothesis that fits the data is unlikely to be a coincidence
- A long hypothesis that fits the data might be a coincidence

#### Arguments opposed:

• There are many ways to define small sets of hypotheses



## **Converting a Tree to Rules**



R₁: If (Outlook=Sunny) ∧ (Humidity=High) Then PlayTennis=No

R<sub>2</sub>: If (Outlook=Sunny) ∧ (Humidity=Normal) Then PlayTennis=Yes

R<sub>3</sub>: If (Outlook=Overcast) Then PlayTennis=Yes

 $R_4$ : If (Outlook=Rain)  $\land$  (Wind=Strong) Then PlayTennis=No

R<sub>5</sub>: If (Outlook=Rain) ∧ (Wind=Weak) Then PlayTennis=Yes



#### **Continuous Valued Attributes**

Create a discrete attribute to test continuous

Temperature = 24.50C

(Temperature > 20.00C) = {true, false}

Where to set the threshold?

| Temperature | 15°C | 18°C | 19ºC | 22ºC | 24ºC | 27ºC |
|-------------|------|------|------|------|------|------|
| PlayTennis  | No   | No   | Yes  | Yes  | Yes  | No   |



#### **Unknown Attribute Values**

What if some examples have missing values of A?

Use training example anyway sort through tree

If node n tests A, assign most common value of A among other examples sorted to node n.

Assign most common value of A among other examples with same target value

Assign probability pi to each possible value vi of A

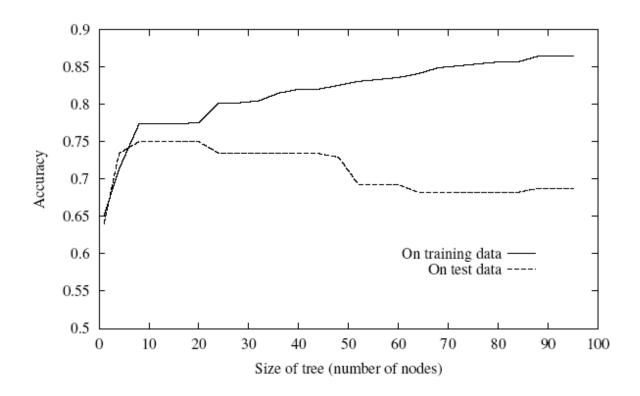
Assign fraction pi of example to each descendant in tree

Classify new examples in the same fashion



## **Overfitting**

One of the biggest problems with decision trees is Overfitting





## **Avoid Overfitting**

stop growing when split not statistically significant grow full tree, then post-prune

Select "best" tree:

measure performance over training data measure performance over separate validation data set min( |tree|+|misclassifications(tree)|)



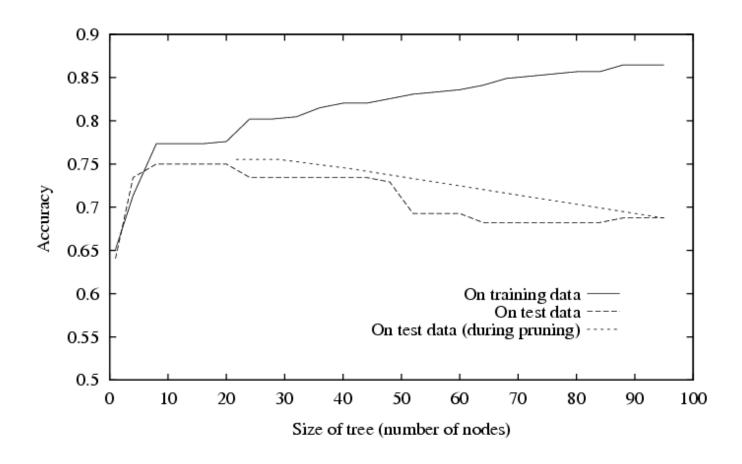
## **Avoid Overfitting**

Idea 1: Stop growing the tree when the error doesn't drop by more than a threshold with any new cut.

Idea 2: Prune a large tree from the leaves to the root. Weakest link pruning:



## **Effect of Reduced Error Pruning**





#### Useful resources

- https://dl.acm.org/citation.cfm?id=541177
- https://towardsdatascience.com/a-guide-to-decision-treesfor-machine-learning-and-data-science-fe2607241956
- https://towardsdatascience.com/entropy-how-decisiontrees-make-decisions-2946b9c18c8
- https://victorzhou.com/blog/information-gain/



# Questions?

